

Análisis exploratorio de los factores determinantes del precio de arrendamiento residencial en India

Julían Isaza Marin,¹
(julian.isazam@udea.edu.co)

Paulina García Aristizábal,²
(paulina.garcia1@udea.edu.co)

¹Fundamentos de ciencia de datos, Facultad de Ingeniería, Universidad de Antioquia, Sede Medellín, 2026.

El presente trabajo analiza los factores determinantes del precio de arrendamiento residencial en India mediante técnicas de ciencia de datos aplicadas sobre el *House Rent Prediction Dataset*, un conjunto de datos públicos con 4.746 registros de propiedades en seis ciudades principales. Siguiendo las tres primeras fases del marco CRISP-DM, se realizó un análisis exploratorio en tres niveles — univariado, bivariado y multivariado —, detección de datos atípicos mediante cuatro métodos complementarios con estrategia de consenso, e imputación y transformación de variables. Los resultados revelan que la ubicación geográfica es el factor más determinante del precio: Mumbai registra una renta mediana de 52.000 INR, seis veces superior a Kolkata (8.500 INR). Entre las variables físicas, el número de baños presenta la correlación más fuerte con el precio (Spearman $\rho = 0.662$), aunque la multicolinealidad entre variables estructurales sugiere la necesidad de reducción dimensional en etapas de modelado. El Análisis de Componentes Principales confirma que dos componentes explican el 87.4% de la varianza total. Se identificaron 141 registros atípicos confirmados (2.97%), correspondientes a propiedades de lujo conservadas con transparencia. El dataset procesado constituye una base sólida para el desarrollo futuro de modelos predictivos de precio de arrendamiento.

Keywords: arrendamiento residencial, análisis exploratorio de datos, detección de outliers, India, preprocesamiento de datos

1 INTRODUCCIÓN

El mercado de arrendamiento residencial constituye uno de los sectores económicos de mayor impacto social en economías emergentes de alta densidad poblacional. En India, con más de 1.400 millones de habitantes y una acelerada migración hacia centros urbanos que proyecta el 40% de la población en ciudades para 2036 [1], la determinación del precio de renta representa una decisión crítica para millones de familias que no acceden a vivienda propia, así como para arrendadores e inversores del sector inmobiliario [2]. La complejidad de este mercado radica en la interacción simultánea de múltiples factores: características físicas del inmueble, nivel de equipamiento, ubicación geográfica y perfil del arrendatario, cuya influencia relativa no es uniforme entre ciudades ni segmentos de mercado.

La ciencia de datos ofrece herramientas metodológicas robustas para abordar esta complejidad. El análisis exploratorio de datos (EDA) permite identificar patrones,

relaciones y anomalías en grandes volúmenes de información antes de cualquier proceso de modelado, constituyendo una fase fundamental del ciclo de vida de un proyecto de datos. En este sentido, el marco metodológico CRISP-DM (*Cross-Industry Standard Process for Data Mining*) proporciona una guía estructurada que abarca desde la comprensión del negocio hasta el despliegue de soluciones, garantizando rigor y trazabilidad en cada etapa del proceso [3].

El presente trabajo aplica las tres primeras fases de CRISP-DM — comprensión del problema, comprensión de los datos y preparación de los datos — sobre el *House Rent Prediction Dataset* [2], un conjunto de datos públicos que, según su autor, recopila información de plataformas digitales de anuncios inmobiliarios sobre 4.746 propiedades en arrendamiento en seis de las principales ciudades de India: Mumbai, Delhi, Bangalore, Hyderabad, Chennai y Kolkata. En este contexto, el presente trabajo formula la siguiente pregunta de investigación: *¿qué características del inmueble y de su ubicación geográfica influyen en la determinación del precio de arrendamiento residencial en las principales ciudades de India, y en qué medida puede cuantificarse su efecto relativo mediante técnicas*

de análisis exploratorio de datos? Para responderla, se aplican técnicas de análisis univariado, bivariado y multivariado, detección y tratamiento de datos atípicos, e imputación y transformación de variables.

Desde una perspectiva ética, el análisis reconoce las limitaciones del dataset en términos de representatividad — al cubrir exclusivamente mercados digitalizados según la fuente original [2] — y la presencia de sesgos de selección en variables como `Tenant Preferred`, cuyo uso en modelos predictivos podría perpetuar patrones de exclusión en el acceso a vivienda [4].

2 METODOLOGÍA

2.1 Fuente y características del conjunto de datos

El análisis se realizó sobre el *House Rent Prediction Dataset* [2], disponible públicamente en la plataforma Kaggle. El conjunto de datos contiene 4.746 registros y 12 variables que describen propiedades en arrendamiento en seis ciudades de India: Mumbai, Delhi, Bangalore, Hyderabad, Chennai y Kolkata. Las variables incluyen características físicas del inmueble (`BHK`, `Size`, `Bathroom`), información de ubicación (`City`, `Area Locality`), condiciones del arrendamiento (`Rent`, `Furnishing Status`, `Tenant Preferred`) y una variable temporal (`Posted On`). El dataset no presenta valores faltantes en su estado original.

2.2 Marco metodológico

El proyecto siguió las tres primeras fases del marco CRISP-DM (*Cross-Industry Standard Process for Data Mining*): comprensión del problema, comprensión de los datos y preparación de los datos. Esta decisión garantizó trazabilidad y rigor metodológico en cada etapa del proceso analítico [3].

2.3 Análisis exploratorio de datos

El EDA se estructuró en tres niveles progresivos. En el nivel univariado se analizaron las distribuciones individuales de `Rent`, `Size`, `BHK`, `Bathroom`, `City` y `Furnishing Status` mediante histogramas y estadísticos descriptivos. Para `Rent`, variable continua de interés principal, se aplicaron pruebas de normalidad de Kolmogorov-Smirnov y Shapiro-Wilk sobre una muestra de 500 observaciones, dado que Shapiro-Wilk pierde potencia estadística con muestras grandes. En el nivel bivariado se cuantificaron las relaciones entre `Rent` y las variables explicativas mediante correlación de Spearman — seleccionada sobre Pearson dado el rechazo de normalidad — y pruebas de Kruskal-Wallis para variables categóricas. En el nivel multivariado se construyó una matriz de correlaciones de Spearman, un mapa de calor de renta mediana por ciudad y nivel de amueblado, y un Análisis de Componentes Principales (PCA) sobre las variables numéricas principales [5].

2.4 Detección y tratamiento de datos atípicos

Se aplicaron cuatro métodos complementarios de detección de outliers: el método IQR con $k = 1.5$, el Z-score sobre las variables transformadas logarítmicamente, Isolation Forest y Local Outlier Factor (LOF), ambos con `contamination=0.05` este valor corresponde al umbral por defecto de scikit-learn y fue seleccionado como estimación conservadora previa al análisis, siendo la estrategia de consenso la que determina el conjunto final de outliers confirmados. [6]. La estrategia de consenso — marcar como outlier confirmado todo registro detectado por al menos dos métodos simultáneamente — identificó 141 observaciones (2.97% del dataset). Estos registros fueron conservados con una variable binaria `es_outlier`, dado que corresponden a propiedades de lujo en Mumbai y no a errores de captura.

2.5 Imputación y transformación de variables

Dado que el dataset no presenta valores faltantes reales, se simuló un escenario MCAR (*Missing Completely at Random*) introduciendo ausencias aleatorias al 8% en las variables `BHK` y `Size`, confirmadas mediante pruebas de Chi-cuadrado y Kruskal-Wallis. Se compararon dos estrategias de imputación — KNN Imputer con $k = 5$ e imputación por mediana — seleccionando KNN por preservar mejor la dispersión original de los datos [7].

Para el tratamiento del sesgo, se aplicó la transformación logarítmica $\log(x+1)$ sobre `Rent` y `Size`, reduciendo el coeficiente de asimetría de 21.41 a 0.91 y de 2.22 a -1.10 respectivamente. Las variables categóricas fueron codificadas mediante Ordinal Encoding para `Furnishing Status` — dada su jerarquía natural — y One-Hot Encoding para `City`. Adicionalmente, se aplicó escalamiento estándar mediante `StandardScaler` sobre las variables `log_Rent`, `log_Size`, `BHK` y `Bathroom`, centrándolas en media cero y varianza unitaria, paso necesario para garantizar la comparabilidad de escalas en el PCA y el KNN Imputer [6].

2.6 Herramientas

El análisis se implementó en Python 3, utilizando las librerías `pandas` y `numpy` para manipulación de datos [7], `matplotlib` y `seaborn` para visualización, `scipy` para pruebas estadísticas, y `scikit-learn` para PCA, imputación y detección de outliers mediante aprendizaje no supervisado [6]. El proyecto está disponible en el repositorio público de GitHub del curso.

3 RESULTADOS Y ANÁLISIS

3.1 Distribución de la variable objetivo

La variable `Rent` presenta una distribución fuertemente asimétrica con un coeficiente de sesgo de 21.41, confirmada por las pruebas de Kolmogorov-Smirnov ($p = 6.87 \times 10^{-47}$) y Shapiro-Wilk ($p = 3.45 \times 10^{-38}$), ambas rechazando la hipótesis de normalidad. La transformación logarítmica redujo el sesgo a 0.91, estabilizando la varianza

y habilitando el uso de métodos de correlación y modelado lineal posteriores (véase Fig. 1).




Fig. 1. Distribución de Rent en escala original (izquierda) y tras la transformación logarítmica (derecha). La transformación reduce el sesgo de 21.41 a 0.91.

Table 1. Estadísticas descriptivas de Rent (INR).

Estadístico	Valor (INR)
Media	35.003
Mediana	16.000
Desviación estándar	78.637
Mínimo	1.200
Percentil 25	10.000
Percentil 75	33.000
Máximo	3.500.000

Table 1 presenta las estadísticas descriptivas de Rent en escala original, evidenciando la alta dispersión del mercado.

3.2 Factores físicos del inmueble

El análisis bivariado mediante correlación de Spearman — seleccionada por la no normalidad de Rent — revela que las tres variables estructurales presentan relación positiva y estadísticamente significativa con el precio ($p < 0.05$ en todos los casos), como se muestra en Table 2.

Table 2. Correlaciones de Spearman entre variables físicas y Rent.

Variable	Spearman ρ	p -valor
Bathroom	0.662	< 0.001
BHK	0.568	< 0.001
Size	0.516	< 0.001

Bathroom resulta ser el predictor individual más robusto ($\rho = 0.662$), seguido de BHK ($\rho = 0.568$) y Size ($\rho = 0.516$). Sin embargo, estas tres variables presentan multicolinealidad crítica entre sí, con correlaciones cruzadas entre 0.721 y 0.776, lo que implica que no deben incluirse simultáneamente en etapas de modelado sin un tratamiento previo de reducción dimensional.

3.3 Factores geográficos y contextuales

La prueba de Kruskal-Wallis confirma que las tres variables categóricas analizadas tienen un efecto estadísticamente significativo sobre Rent.

Table 3. Resultados de la prueba de Kruskal-Wallis para variables categóricas.

Variable	H	p -valor
City	1613.674	< 0.001
Furnishing Status	423.495	< 0.001
Tenant Preferred	177.237	< 0.001

La ciudad es el factor categórico más determinante ($H = 1613.674$), coherente con la brecha de 6x en renta mediana entre Mumbai (52.000 INR) y Kolkata (8.500 INR). El heatmap de Fig. 2 revela además que la prima por amueblado no es uniforme: en Mumbai la diferencia entre *Furnished* y *Unfurnished* alcanza 35.000 INR, mientras que en Kolkata apenas supera los 2.000 INR.




Fig. 2. Renta mediana (miles de INR) por ciudad y estado de amueblado. Mumbai opera en una escala de precios completamente aislada respecto al resto de ciudades.

Fig. 3 complementa este análisis mostrando la distribución completa de Rent para cada variable categórica. La asimetría positiva y la densidad de valores atípicos son consistentes en todas las categorías, confirmando que la variabilidad del precio no se explica únicamente por los factores categóricos sino por la interacción entre ubicación, características físicas y nivel de equipamiento.




Fig. 3. Distribución de Rent por ciudad, estado de amueblado e inquilino preferido. La escala logarítmica evidencia la asimetría del mercado y la posición dominante de Mumbai en todas las categorías.

3.4 Estructura multivariada

El PCA aplicado sobre las variables numéricas principales revela que PC1 concentra el 69.6% de la varianza

total, representando la dimensión estructural de la vivienda — agrupa Size, BHK y Bathroom con vectores de carga casi paralelos. PC2 captura el 18.1% adicional y representa la dimensión del costo neto, dominada por Rent con una proyección casi ortogonal al bloque estructural. Con solo dos componentes se explica el 87.7% de la varianza total, validando la viabilidad de reducción dimensional para etapas de modelado futuras [5].




Fig. 4. Biplot del PCA coloreado por ciudad. PC1 representa la dimensión estructural y PC2 el costo neto. Mumbai se despliega hacia los cuadrantes de alta infraestructura y alto costo.

3.5 Detección de datos atípicos

La Table 4 resume los resultados de los cuatro métodos de detección aplicados. La estrategia de consenso (≥ 2 métodos) identificó 141 registros atípicos confirmados (2.97% del dataset), con una renta mediana de 255.000 INR — 17 veces superior a la mediana general (16.000 INR).

Table 4. Comparación de métodos de detección de outliers sobre Rent y Size.

Método	Outliers detectados	% del dataset
IQR ($k = 1.5$)	520	11.0%
Z-score (log)	37	0.8%
Isolation Forest	238	5.0%
LOF	238	5.0%
Consenso (≥ 2)	141	2.97%




Fig. 5. Comparación de métodos de detección de outliers en el espacio $\log(\text{Size})$ vs $\log(\text{Rent})$. De izquierda a derecha: IQR, Isolation Forest y LOF. Ilustra cómo cada método delimita el espacio bivariado de forma distinta: el IQR sobredetecta con un corte horizontal rígido, mientras que Isolation Forest y LOF capturan anomalías multivariadas con mayor precisión geométrica y local respectivamente.

3.6 Imputación de valores faltantes

Dado que el dataset no presenta faltantes reales, se simuló un escenario MCAR al 8% sobre BHK y Size para demostrar el flujo completo de imputación. Fig. 6 compara las distribuciones resultantes de KNN Imputer ($k = 5$) e imputación por mediana frente a los valores originales.

Para BHK, la mediana genera una acumulación artificial sobre el valor 2.0, mientras que KNN distribuye los valores imputados de forma más proporcional. Para Size, la diferencia es más marcada: la mediana introduce un pico artificial que reduce la varianza natural, mientras que KNN replica con mayor fidelidad la asimetría positiva original. Esta diferencia se cuantifica en la desviación estándar: KNN presenta un error de 17.285 frente a 29.163 de la mediana, justificando su selección como estrategia definitiva.




Fig. 6. Comparación de estrategias de imputación para BHK (superior) y Size (inferior). KNN preserva mejor la distribución original que la imputación por mediana en ambas variables.

4 CONCLUSIONES

El presente trabajo aplicó las tres primeras fases del marco CRISP-DM sobre el *House Rent Prediction Dataset* para identificar y cuantificar los factores determinantes del precio de arrendamiento residencial en seis ciudades de India. Los resultados permiten responder la pregunta de investigación con evidencia estadística robusta.

La ubicación geográfica es el factor más determinante del precio, superando en capacidad diferenciadora a cualquier característica física del inmueble. Mumbai opera en una escala de precios estructuralmente aislada — con una renta mediana de 52.000 INR y un costo por pie cuadrado de aproximadamente 80 INR/sqft — mientras que Kolkata representa el extremo opuesto con 8.500 INR de mediana y menos de 15 INR/sqft. Dentro de las variables físicas, el número de baños resultó ser el predictor individual más robusto ($p = 0.662$), seguido de BHK ($p = 0.568$) y Size ($p = 0.516$), aunque la multicolinealidad crítica entre estas tres variables (p entre 0.721 y 0.776) indica que deben tratarse conjuntamente en etapas de modelado mediante técnicas de reducción dimensional.

El nivel de amueblado actúa como modulador secundario cuyo impacto económico real depende del mercado local.

Desde el punto de vista metodológico, la no normalidad de `Rent` (sesgo = 21.41) determinó el uso consistente de pruebas no paramétricas — Spearman sobre Pearson, Kruskal-Wallis sobre ANOVA — a lo largo de todo el análisis bivariado. La estrategia de consenso en la detección de outliers demostró ser más robusta que cualquier método individual, identificando 141 registros (2.97%) correspondientes a propiedades de lujo en Mumbai que fueron conservados con transparencia mediante la variable `es_outlier`. La transformación logarítmica fue la intervención de preprocesamiento más efectiva, reduciendo el sesgo de `Rent` un 96%.

En cuanto a las limitaciones del estudio, el dataset cubre exclusivamente mercados digitalizados de seis grandes ciudades, excluyendo el mercado informal de arrendamiento que representa una fracción significativa de la realidad habitacional india. Adicionalmente, la variable `Tenant Preferred` incorpora sesgos de selección que podrían perpetuar patrones de exclusión si se utiliza en modelos predictivos [4].

Como extensión natural, el dataset procesado — con variables transformadas, codificadas y documentadas — constituye una base sólida para la construcción de modelos de regresión que permitan predecir el precio de renta, o para análisis de clustering que segmenten el mercado de forma más granular. La incorporación de datos del mercado informal y de ciudades intermedias representaría una mejora sustancial en la representatividad del análisis.

5 REFERENCES

- [1] World Bank, “Gearing up for India’s Rapid Urban Transformation,” <https://www.worldbank.org/en/news/opinion/2024/01/30/gearing-up-for-india-s-rapid-urban-transformation> (2024 enero), opinion piece, The Economic Times.
- [2] S. Banerjee, “House Rent Prediction Dataset,” (2022), <https://www.kaggle.com/datasets/iamsouravbanerjee/house-rent-prediction-dataset>, accessed: May 2026.
- [3] A. Field, *Discovering Statistics Using IBM SPSS Statistics* (SAGE Publications, 2018), 5th ed.
- [4] E. Rahm and H. H. Do, “Data Cleaning: Problems and Current Approaches,” *IEEE Data Engineering Bulletin*, vol. 23, no. 4, pp. 3–13 (2000).
- [5] I. T. Jolliffe and J. Cadima, “Principal Component Analysis: A Review and Recent Developments,” *Philosophical Transactions of the Royal Society A*, vol. 374, no. 2065 (2016), <https://doi.org/10.1098/rsta.2015.0202>.
- [6] F. Pedregosa et al., “Scikit-learn: Machine Learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830 (2011).
- [7] W. McKinney, *Python for Data Analysis* (O’Reilly Media, 2022), 3rd ed.